Algorithmes d’apprentissage non supervisé

01-04

Validation du partitionnement

@ 2026 MKL.AI - Tous droits réservés.

Au programme

- Le défi de l’apprentissage non supervisé
- Cohésion et séparation
- Coefficient de Silhouette
- Indice de Davies-Bouldin
- Indice de Calinski-Harabasz
- Matrice de décision
- Validation du partitionnement avec scikit-learn
- Ateliers
- Lectures et références

@ 2026 MKL.AI - Tous droits réservés.

Le défi de l’apprentissage non supervisé

Le défi de l’apprentissage non supervisé

- En apprentissage supervisé, nous avons la **vérité “terrain”** (étiquettes) pour calculer la performance (précision, …)

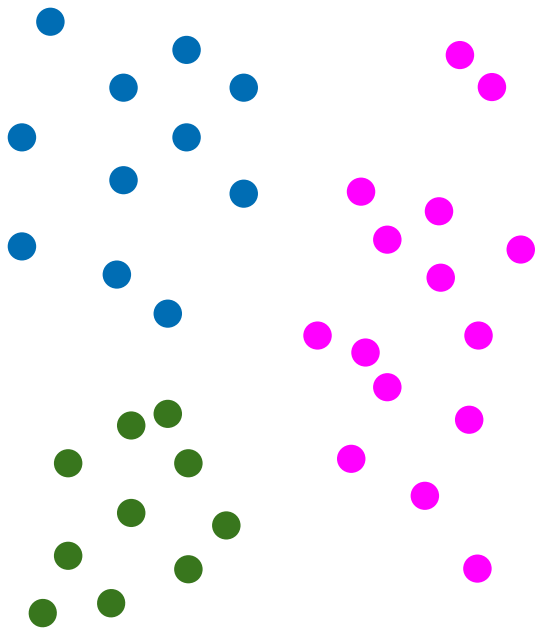

@ 2026 MKL.AI - Tous droits réservés.

Le défi de l’apprentissage non supervisé

- En apprentissage supervisé, nous avons la **vérité “terrain”** (étiquettes) pour calculer la performance (précision, …)
- En partitionnement, cette vérité n’existe pas → Comment savoir si une partition est pertinente / de qualité ?
- L’inspection visuelle est impossible en haute dimension

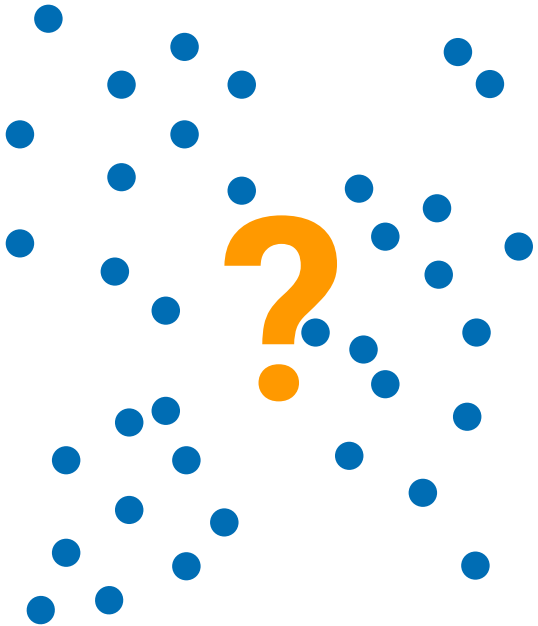

Combien de clusters ?

@ 2026 MKL.AI - Tous droits réservés.

Cohésion et séparation

Deux “forces” opposées

Maximiser la distance inter-clusters → **Séparation**

Minimiser la distance intra-cluster → **Cohésion**

Évaluer un modèle revient à mesurer mathématiquement l’équilibre entre ces deux forces opposées

@ 2026 MKL.AI - Tous droits réservés.

Coefficient de Silhouette

- C'est l'un des outils les plus populaires car il combine cohésion et séparation pour chaque point (i)

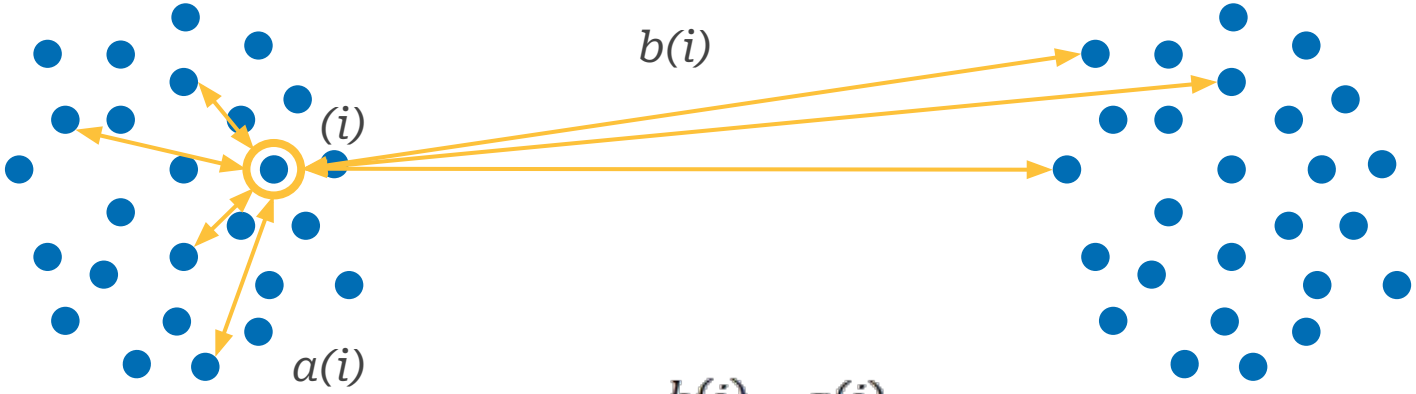

$$s(i) = \frac{b(i) - a(i)}{\max\left(a(i), b(i)\right)}$$

@ 2026 MKL.AI - Tous droits réservés.

Silhouette: interprétation

- Proche de +1 : Le point est très bien classé (loin du cluster voisin et proche du sien).

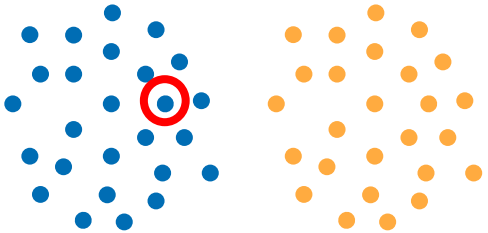

- Proche de 0 : Le point est à la frontière entre deux clusters.

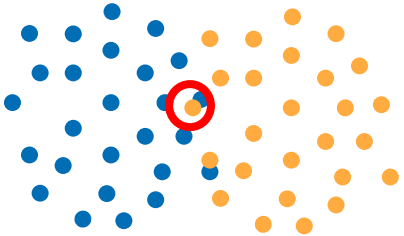

- Proche de -1 : Le point est probablement dans le mauvais cluster.

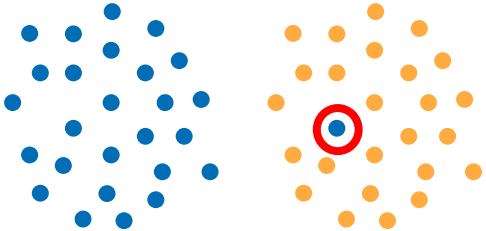

@ 2026 MKL.AI - Tous droits réservés.

Silhouette: score global

- On calcule la moyenne des $s(i)$ pour tous les points. Plus la moyenne est élevée, meilleur est le partitionnement.

$$S = \frac{1}{N}\sum_{i=1}^{N} s(i)$$

- Où :
  - N : nombre d'observations
  - $s(i)$: scores de Silhouette individuels

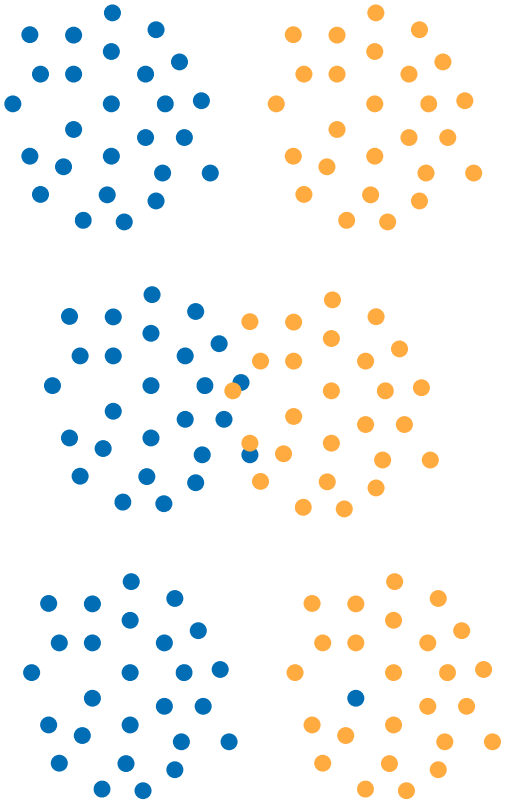

@ 2026 MKL.AI - Tous droits réservés.

Quiz

- Dans le contexte du partitionnement, que signifie le concept de « Cohésion » ?

  A. La maximisation de la distance entre les centroïdes des différents clusters.

  B. L’affectation d’un point à plusieurs clusters simultanément.

  C. La minimisation de la distance entre les points au sein d’un même cluster.

  D. Le ratio entre le nombre total de clusters et le nombre total d’observations.

@ 2026 MKL.AI - Tous droits réservés.

Quiz

- Vous calculez le score de Silhouette individuel $s(i)$ pour un point spécifique et obtenez -0.85. Que pouvez-vous en déduire sur ce point ?

  A. Il est probablement assigné au mauvais cluster.

  B. Il se situe exactement à la frontière entre deux clusters.

  C. C’est impossible car le score de Silhouette ne peut prendre que des valeurs positives ou nulles.

  D. Il est très bien classé et proche de son centroïde.

@ 2026 MKL.AI - Tous droits réservés.

Indice de Davies-Bouldin

Indice de Davies-Bouldin

L'indice de Davies-Bouldin évalue le "pire scénario" de chevauchement entre les clusters.

- Il calcule le ratio entre la dispersion moyenne (conhésion) combinée des clusters (s_i + s_j) et la distance entre leurs centroïdes (d_{ij}).
- Contrairement à la silhouette, on cherche à **minimiser** cet indice. Un score plus bas indique que les clusters sont moins "étalés" et mieux séparés.

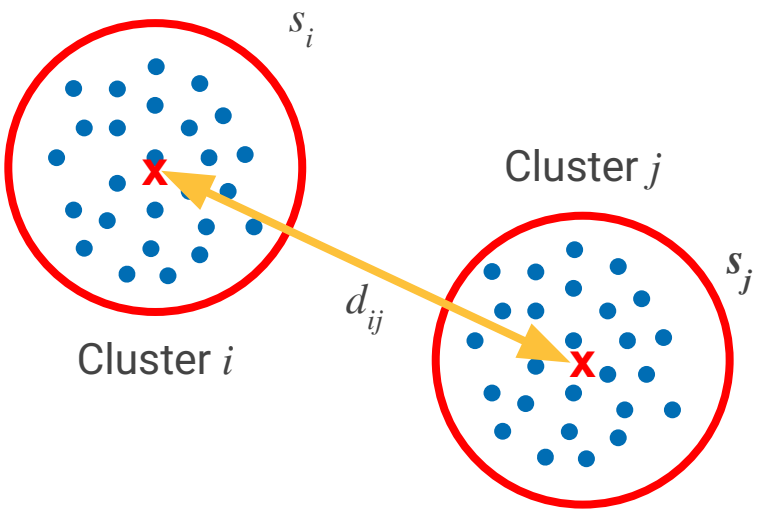

@ 2026 MKL.AI - Tous droits réservés.

Indice de Davies-Bouldin

- L’indice se calcule par:

$$DB = \frac{1}{k} \sum_{i=1}^{k} \max_{j \neq i} \left(\frac{s_i + s_j}{d_{ij}} \right)$$

- Où :
  - s_i : dispersion moyenne du cluster i
  - d_{ij} : distance entre les centroïdes des clusters i et j

- Un score de 0 est le score parfait.
- C'est une métrique plus simple et plus rapide à calculer que la Silhouette.

@ 2026 MKL.AI - Tous droits réservés.

Indice de Davies-Bouldin

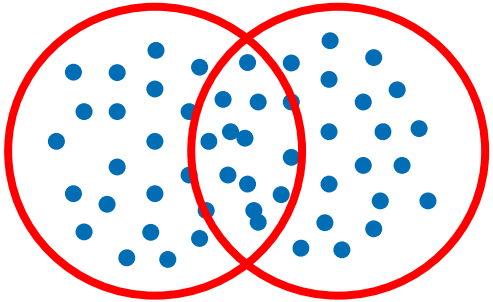

Score élevé (mauvais)

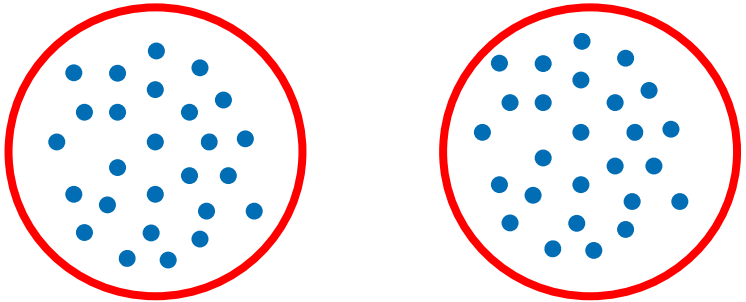

Score=0 (parfait)

@ 2026 MKL.AI - Tous droits réservés.

Indice de Calinski-Harabasz

Indice de Calinski-Harabasz

Aussi appelé "critère du ratio de variance".

- C'est le rapport entre la variance inter-clusters et la variance intra-cluster.
- On cherche à **maximiser** ce score. Un score élevé signifie que les clusters sont denses et bien espacés.

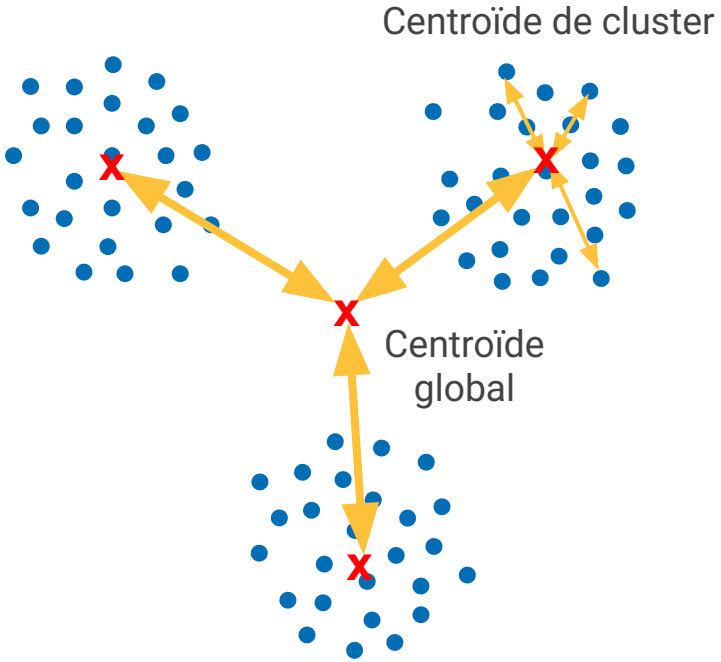

@ 2026 MKL.AI - Tous droits réservés.

Indice de Calinski-Harabasz

L’indice se calcule par :

$$CH = \frac{SS_B/(k-1)}{SS_W/(n-k)}$$

Où :

- SS_B: somme des carrés inter-cluster
- SS_W: somme des carrés intra-cluster
- k : nombre de clusters
- n: nombre d'observations

- Plus le score est **élevé**, mieux c'est.
- C'est l'indice le plus **rapide** à calculer sur de très grands jeux de données.

@ 2026 MKL.AI - Tous droits réservés.

Matrice de décision

Matrice de décision

Métrique	Échelle	Objectif	Rapidité	Cas d'usage
Silhouette	-1 à +1	Maximiser	Lente ($O(N^2)$)	Petits jeux de données
Davies-Bouldin	0 à ∞	Minimiser	Moyenne	Alternative plus rapide, focalisée sur le pire scénario de chevauchement
Calinski-Harabasz	0 à ∞	Maximiser	Très rapide	Jeux de données massifs. Évaluation instantanée basée sur la variance globale

@ 2026 MKL.AI - Tous droits réservés.

Validation du partitionnement avec scikit-learn

Validation du partitionnement avec scikit-learn

```python
from sklearn.metrics import silhouette_score, davies_bouldin_score, calinski_harabasz_score

# Hypothèse : 'X' représente vos données et 'labels' les résultats du partitionnement
s_score = silhouette_score(X, labels)
db_score = davies_bouldin_score(X, labels)
ch_score = calinski_harabasz_score(X, labels)

print(f"Silhouette: {s_score:.3f}")
print(f"Davies-Bouldin: {db_score:.3f}")
print(f"Calinski-Harabasz: {ch_score:.3f}")

# https://scikit-learn.org/stable/api/sklearn.metrics.html#module-sklearn.metrics.cluster
```

@ 2026 MKL.AI - Tous droits réservés.

Quiz

- Vous travaillez sur un jeu de données massif comptant des millions d'observations. Quelle métrique privilégierez-vous pour avoir une évaluation quasi-instantanée de votre modèle ?

  A. L'indice de Davies-Bouldin

  B. Vous utilisez la technique du coude

  C. Le coefficient de Silhouette

  D. L'indice de Calinski-Harabasz

@ 2026 MKL.AI - Tous droits réservés.

Ateliers

https://github.com/mswawola-cegep/420-a58-sf-gr-12022-hiver-2026.git

01-04

@ 2026 MKL.AI - Tous droits réservés.

Lectures et références

Lectures

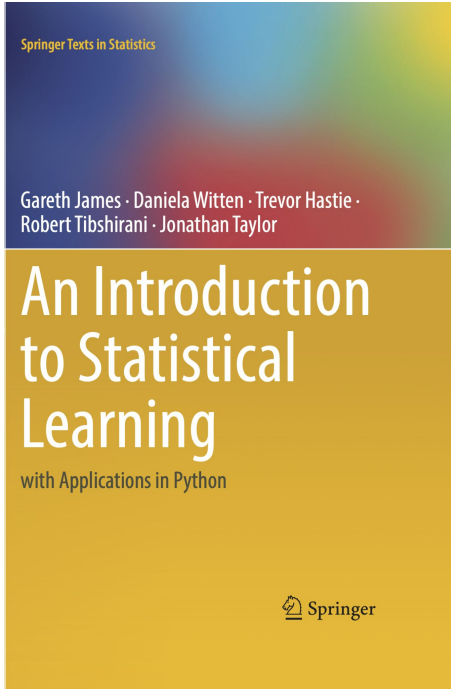

- Introduction to Statistical Learning with Applications in Python (2023)

  → 12.4 Clustering Methods

@ 2026 MKL.AI - Tous droits réservés.

Références

[1] CS229: Machine Learning - Stanford University

[2] Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani and Jonathan Taylor, “Introduction to Statistical Learning with Applications in Python”

@ 2026 MKL.AI - Tous droits réservés.