Algorithmes d’apprentissage non supervisé

02-02

Représentation des documents et métriques de distances

@ 2026 MKL.AI - Tous droits réservés.

Au programme

- Représentation des documents
- Métriques de distances
- Ateliers
- Lectures et références

@ 2026 MKL.AI - Tous droits réservés.

Représentation des documents

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l’ordre des mots
  - Compte le nombre d’occurence de chaque mot

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l’ordre des mots
  - Compte le nombre d’occurence de chaque mot

Messi est un joueur de foot de l’équipe d’Argentine. Au Québec, le foot est appelé “soccer”

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l’ordre des mots
  - Compte le nombre d’occurence de chaque mot

Messi est un joueur de foot de l’équipe d’Argentine. Au Québec, le foot est appelé “soccer”

1												
Messi												

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi **est** un joueur de foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1											
Messi	est											

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est **un** joueur de foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1	1										
Messi	est	un										

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est un **joueur** de foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1	1	1									
Messi	est	un	joueur									

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est un joueur **de** foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1	1	1	1								
Messi	est	un	joueur	de								

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est un joueur de **foot** de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1	1	1	1	1							
Messi	est	un	joueur	de	foot							

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est un joueur de foot **de** l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1	1	1	2	1							
Messi	est	un	joueur	de	foot							

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est un joueur de foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

1	1	1	1	2	1	1						
Messi	est	un	joueur	de	foot	le						

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l’ordre des mots
  - Compte le nombre d’occurence de chaque mot

Messi est un joueur de foot de l’**équipe** d’Argentine. Au Québec, le foot est appelé “soccer”

1	1	1	1	2	1	1	1					
Messi	est	un	joueur	de	foot	le	équipe					

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l’ordre des mots
  - Compte le nombre d’occurence de chaque mot

Messi est un joueur de foot de l’équipe **d**’Argentine. Au Québec, le foot est appelé “soccer”

1	1	1	1	3	1	1	1					
Messi	est	un	joueur	de	foot	le	équipe					

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot

Messi est un joueur de foot de l'équipe d'**Argentine**. Au Québec, le foot est appelé "soccer"

1	1	1	1	3	1	1	1	1				
Messi	est	un	joueur	de	foot	le	équipe	Argentine				

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l’ordre des mots
  - Compte le nombre d’occurence de chaque mot

Messi est un joueur de foot de l’équipe d’Argentine. Au Québec, le foot est appelé “soccer”

1	2	1	1	3	2	2	1	1	1	1	1	1
Messi	est	un	joueur	de	foot	le	équipe	Argentine	au	Québec	appelé	soccer

@ 2026 MKL.AI - Tous droits réservés.

Représentation word count

- Modèle **sac de mots** (bag of words)
  - Ignore l'ordre des mots
  - Compte le nombre d'occurence de chaque mot
  - Équivalent à un **histogramme**

Messi est un joueur de foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer"

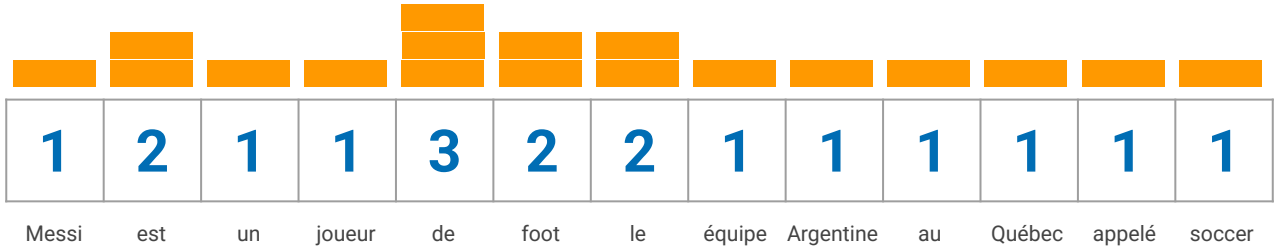

@ 2026 MKL.AI - Tous droits réservés.

Selon vous, quels sont les inconvénients de cette représentation ?

Représentation word count - Inconvénients

- Les mots **fréquents** dominent les mots **rares**
- **le** / **de** / **est** / **foot**
- **Messi** / **soccer** / **etc ...**

Messi est un joueur de foot de l'équipe d'Argentine. Au Québec, le foot est appelé "soccer" ...

1	2	1	1	3	2	2	1	1	1	1	1	1
Messi	est	un	joueur	de	foot	le	équipe	Argentine	au	Québec	appelé	soccer

@ 2026 MKL.AI - Tous droits réservés.

Représentation TF-IDF

- La représentation TF-IDF met l’accent sur **les mots importants**
  - **Term Frequency** (TF) - Fréquence d’apparition dans le document (local)

TF =

					word count							

@ 2026 MKL.AI - Tous droits réservés.

Représentation TF-IDF

- La représentation TF-IDF met l'accent sur **les mots importants**
  - **Term Frequency** (TF) - Fréquence d'apparition dans le document (local)

TF =

					word count							

IDF =

			$\log \frac{\#\text{documents}}{1+\#\text{documents utilisant le mot}}$									

@ 2026 MKL.AI - Tous droits réservés.

Représentation TF-IDF

- **Term Frequency Inverse Document Frequency** (TF-IDF)

$$\text{TF-IDF} = \text{word count} \times \log \frac{\#\text{documents}}{1 + \#\text{documents utilisant le mot}}$$

TF =

x

IDF =

=

TF-IDF =

@ 2026 MKL.AI - Tous droits réservés.

Représentation TF-IDF

- La plupart du temps, TF est **normalisée**.
- Plages de variation:

Élément	**Intervalle**
TF brut	$[0,+\infty)$
TF normalisé	$[0,1]$
IDF	$[0,\log(N)]$
TF-IDF sans normalisation	$[0,+\infty)$
TF-IDF normalisé (L2)	chaque valeur $\in[0,1]$, norme = 1

@ 2026 MKL.AI - Tous droits réservés.

Représentation TF-IDF

- TF-IDF mesure l’importance relative d’un mot dans un document par rapport à tout le corpus, et ses valeurs ne sont bornées entre 0 et 1 que lorsqu’une normalisation est appliquée.
- Compromis entre **fréquence locale** et **rareté globale**

@ 2026 MKL.AI - Tous droits réservés.

Métriques de distances

Métriques de distance: notion de “plus proche”

- En 1D, **distance euclidienne**

$$\text{distance}\left(x_i, x_q\right) = \left|x_i - x_q\right|$$

- Dans le cas de plusieurs dimensions:
  - Il existe plusieurs **fonctions de distance** intéressantes
  - Fléau de la dimension
  - Il peut être intéressant d’appliquer un **poids différent** à chaque dimension (feature weight)

@ 2026 MKL.AI - Tous droits réservés.

Feature weight

- Tout simplement parce que certaines dimensions / variables peuvent être plus **importantes** que d'autres !

Nombre de chambres

Nombre de salles de bain

Superficie habitable

Superficie du terrain

Nombre d'étages

Vue panoramique

Année de construction

....

@ 2026 MKL.AI - Tous droits réservés.

Feature weight

- Tout simplement parce que certaines dimensions / variables peuvent être plus **importantes** que d'autres !

Nombre de chambres

Nombre de salles de bain

Superficie habitable

Superficie du terrain

Nombre d'étages

Vue panoramique

Année de construction

....

@ 2026 MKL.AI - Tous droits réservés.

Feature weight

- Tout simplement parce que certaines dimensions / variables peuvent être plus **importantes** que d'autres !

Titre

Abstract

Texte principal

Sous-titres

Conclusion

....

@ 2026 MKL.AI - Tous droits réservés.

Feature weight

- Tout simplement parce que certaines dimensions / variables peuvent être plus **importantes** que d'autres !

Titre

Abstract

Texte principal

Sous-titres

Conclusion

....

@ 2026 MKL.AI - Tous droits réservés.

Mise à l'échelle revisitée

- Tout simplement parce que certaines dimensions / variables peuvent être plus **importantes** que d'autres !
- Également, certaines variables varient plus que d'autres

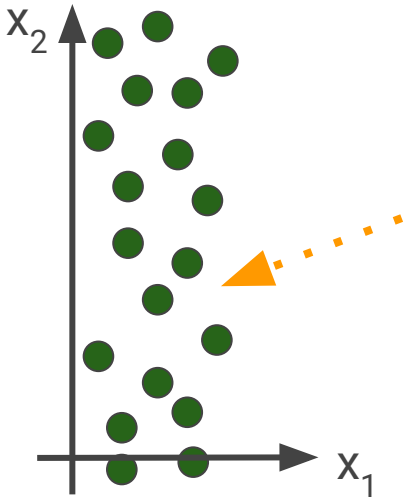

Les faibles variations de x_1 "comptent plus" que les fortes variations de x_2

Choisir des poids en fonction de l' étendue des variables

@ 2026 MKL.AI - Tous droits réservés.

Distance euclidienne pondérée

- Formellement:

$$\text{distance}(x_i, x_q) = \sqrt{a_1(x_{i1} - x_{q1})^2 + \cdots + a_n(x_{in} - x_{qn})^2}$$

$a_1, a_2, \ldots, a_n$ sont les poids appliqués aux différentes variables.
Permet de définir l'importance relative

@ 2026 MKL.AI - Tous droits réservés.

Poids binaires

- Formellement:

$$\text{distance}\left(x_i, x_q\right) = \sqrt{a_1\left(x_{i1} - x_{q1}\right)^2 + \cdots + a_n\left(x_{in} - x_{qn}\right)^2}$$

Choisir 0 ou 1 comme poids permet de réaliser une sélection de variables

@ 2026 MKL.AI - Tous droits réservés.

Poids binaires

- Formellement:

$$\text{distance}\left(x_i, x_q\right) = \sqrt{a_1\left(x_{i1} - x_{q1}\right)^2 + \cdots + a_n\left(x_{in} - x_{qn}\right)^2}$$

L’ingénierie de données devrait avoir été couverte par le cours **420-A56-SF - Transformation et manipulation des données**

Choisir 0 ou 1 comme poids permet de réaliser une sélection de variables

@ 2026 MKL.AI - Tous droits réservés.

Distance euclidienne (non pondérée)

- La distance euclidienne peut-être définie par un produit de deux vecteurs:

$$\text{distance}\left(x_i, x_q\right) = \sqrt{\left(x_{i1} - x_{q1}\right)^2 + \cdots + \left(x_{in} - x_{qn}\right)^2}$$

@ 2026 MKL.AI - Tous droits réservés.

Distance euclidienne (non pondérée)

- La distance euclidienne peut-être définie par un produit de deux vecteurs:

$$\text{distance}(x_i, x_q) = \sqrt{(x_{i1} - x_{q1})^2 + \cdots + (x_{in} - x_{qn})^2} \qquad = \sqrt{(x_i - x_q)^T (x_i - x_q)}$$

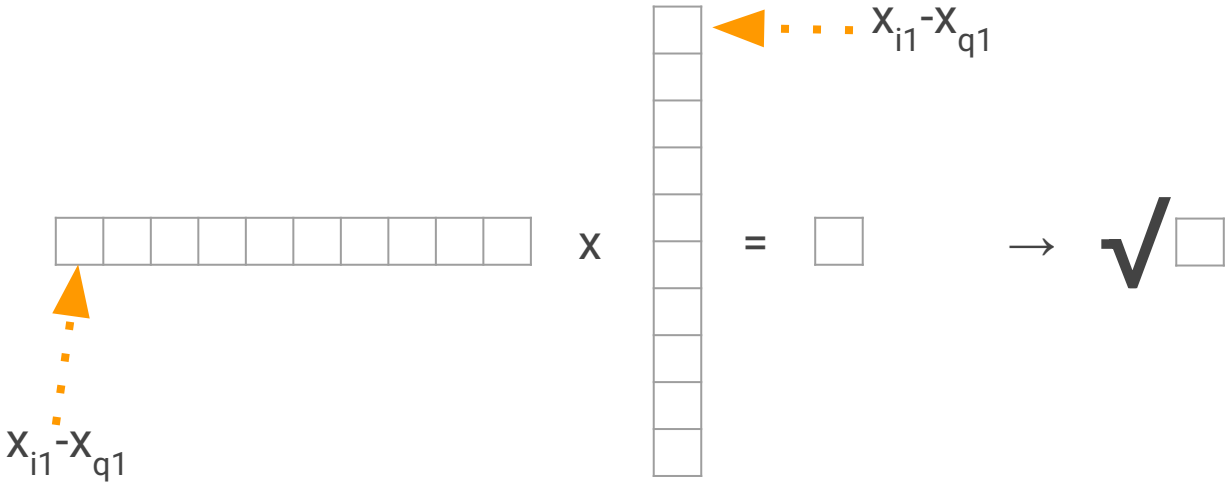

@ 2026 MKL.AI - Tous droits réservés.

Distance euclidienne pondérée

- La dist. euclidienne pondérée peut-être définie par un produit de deux vecteurs:

$$\text{distance}(x_i, x_q) = \sqrt{a_1(x_{i1} - x_{q1})^2 + \cdots + a_n(x_{in} - x_{qn})^2} = \sqrt{(x_i - x_q)^T A (x_i - x_q)}$$

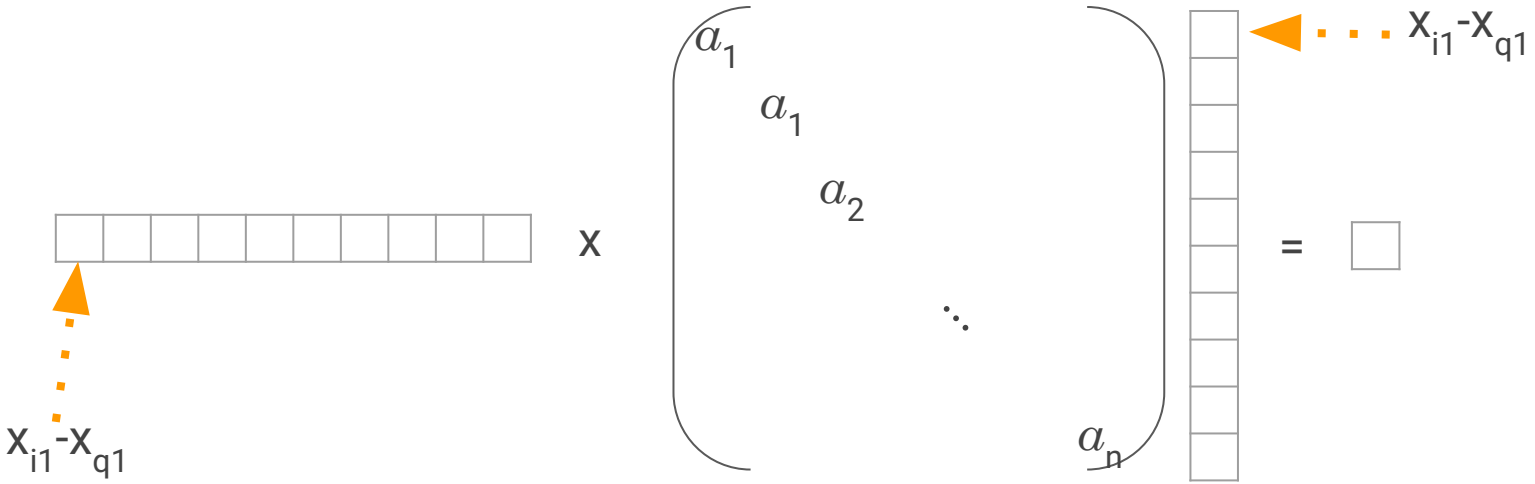

@ 2026 MKL.AI - Tous droits réservés.

Mesure de similarité

x_q

1	0	0	0	3	5	0	0	1	2

Similarité = $x_i^T x_q$

x_i

3	0	0	0	0	2	0	0	1	1

Que vaut la similarité ?

@ 2026 MKL.AI - Tous droits reservés.

Mesure de similarité

x_q

1	0	0	0	3	5	0	0	1	2

Similarité = $x_i^T x_q$

x_i

0	0	4	7	1	0	2	0	1	0

Que vaut est la similarité ?

@ 2026 MKL.AI - Tous droits réservés.

Normalisation de la similarité

$$\text{Similarité} = x_i^T x_q \xrightarrow{\text{Normalisation}} \frac{x_i^T x_q}{x_i^T x_i \; x_q^T x_q} \longleftrightarrow \left(\frac{x_i}{x_i^T x_i}\right)^T \frac{x_q}{x_q^T x_q}$$

$$a^T b = ||a|| \times ||b|| \times cos(\theta) \longrightarrow \frac{x_i^T}{||x_i||} \frac{x_q}{||x_q||} = \cos(\theta)$$

Similarité cosinus !

@ 2026 MKL.AI - Tous droits réservés.

Exercice: normaliser le vecteur suivant

1	0	0	0	3	5	0	0	1	0

1/6	0	0	0	3/6	5/6	0	0	1/6	0

@ 2026 MKL.AI - Tous droits réservés.

Similarité cosinus

- D’une manière générale, la similarité cosinus est comprise entre -1 et 1

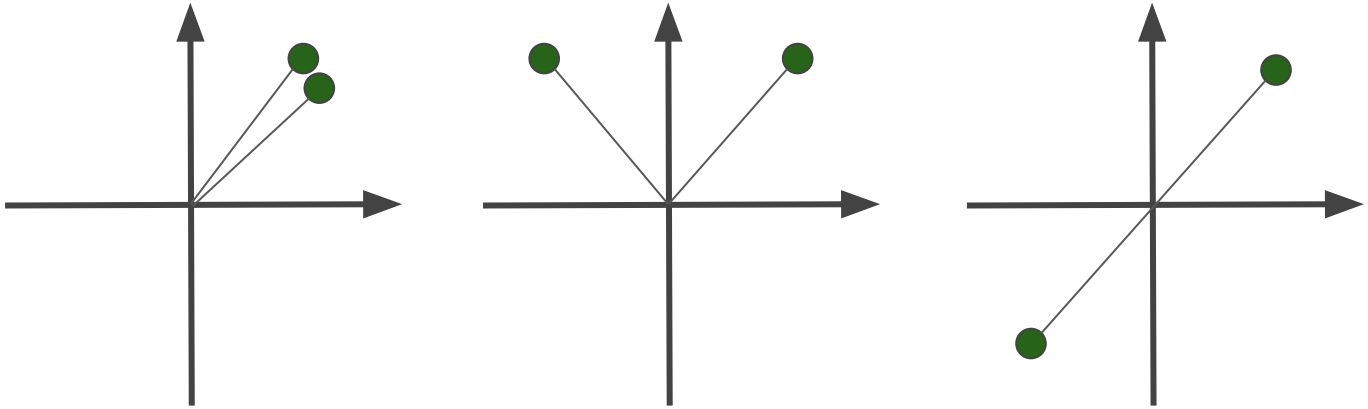

θ très petit

θ ~ 90°

θ ~ 180°

Quels sont les cosinus de ces angles ?

@ 2026 MKL.AI - Tous droits réservés.

Similarité cosinus

- D’une manière générale, la similarité cosinus est comprise entre -1 et 1

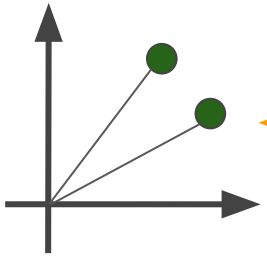

Pour TF-IDF, θ dans ce cadran
similarité comprise entre 0 et 1

Question pourquoi ?

- Nous pouvons aussi définir la distance cosinus: **distance = 1 - similarité**

@ 2026 MKL.AI - Tous droits réservés.

Normaliser ou pas ?

1	0	0	0	3	5	0	0	1	0

4

x2

Oui !

2	0	0	0	6	10	0	0	2	0

16

0	0	4	7	1	0	2	0	1	0

x2

0	0	8	14	2	0	4	0	2	0

© 2026 MKL.AI - Tous droits réservés.

Normaliser ou pas ?

Document volumineux

Tweet

La normalisation peut rendre des objets différents similaires

Non …

Document volumineux

Document volumineux

Autres métriques de distance

- **Basée sur la corrélation**
- **Mahalanobis**
- Rank-based
- **Manhattan**
- Jaccard
- Hamming
- ...

@ 2026 MKL.AI - Tous droits réservés.

Combinaison de métriques - Exemple

- Texte des documents
  - Similarité cosinus
- Nombre de lectures des documents
  - Distance euclidienne
- Affecter un poids différent à chaque métrique

@ 2026 MKL.AI - Tous droits réservés.

Ateliers

https://github.com/mswawola-cegep/420-a58-sf-gr-12022-hiver-2026.git

02-02-A1

@ 2026 MKL.AI - Tous droits réservés.

https://github.com/mswawola-cegep/420-a58-sf-gr-12022-hiver-2026.git

02-02-A2

@ 2026 MKL.AI - Tous droits réservés.

Lectures et références

Références

[1] Machine Learning: Clustering and Retrieval - Emily Fox & Carlos Guestrin - University of Washington

@ 2026 MKL.AI - Tous droits réservés.